

한국어 sLLM 기반 말하기 문제 자동 생성 및 적합성 평가 파이프라인

서준^o, 황선정¹, 이근배^{1,2}
포항공과대학교 인공지능대학원^{o,1}, 포항공과대학교 컴퓨터공학과²
{sjin4861, seonjeongh, gblee}@postech.ac.kr

A Korean sLLM Pipeline for Generation and Suitability Evaluation of Speaking Items

Jun Seo^o, Seonjeong Hwang¹, Gary Geunbae Lee^{1,2}
Graduate School of Artificial Intelligence, Pohang University of Science and Technology^{o,1}
Department of Computer Science and Engineering, Pohang University of Science and Technology²

요약

전 세계 한국어 학습 수요가 크게 증가하면서, L2 학습자의 말하기 능력을 평가할 수 있는 고품질 문항을 대규모로 확보하는 것이 중요한 과제로 떠오르고 있다. 본 연구에서는 한국의 일상생활과 관련된 250개의 소재(topic)를 기반으로 최신 한국어 sLLM(7~12B)을 활용하여 말하기 문제를 자동 생성하고 결과물의 적합성을 평가하는 파이프라인을 설계하였다. 파이프라인 분석 결과, 특정 모델은 약 7B 규모에도 불구하고 명세 충실성과 언어적 완성도 측면에서 안정적인 성능을 보였다. 추가적으로, 파이프라인에서 생성된 데이터로 선호도 쌍(pairwise preference) 데이터셋을 구축하고, L2 학습자에게 적합한 문항을 판별하는 소형 평가기(2B)를 훈련시켰다. 테스트 데이터셋 실험 결과, 소형 평가기의 평가 결과는 중형 규모 LLM(32B)의 평가 결과와 유의미한 양의 순위 상관관계($\rho = 0.573$)를 보였다. 이는 특정 LLM 단독 평가에서 발생할 수 있는 편향을 일정 부분 보완하고 평가 단계의 비용 부담을 완화할 수 있는 가능성을 시사한다. 본 연구는 한국어 sLLM을 활용한 말하기 문제 자동 생성 및 적합성 평가 파이프라인을 구축하였으며, 구축된 데이터와 방법론은 향후 L2 학습자 말하기 평가 연구의 기초 자료로 활용될 수 있다.

주제어: L2 한국어 말하기 평가, 한국어 sLLM, 자동 문항 생성, 자동 문항 평가, 선호도 학습

제 1. 절 서론

한국 문화 콘텐츠의 국제적 인기는 한국어 학습에 대한 전 세계적 수요를 크게 증가시켰다[1]. 이에 따라 L2 학습자의 말하기 능력을 평가할 수 있는 고품질 문제를 대규모로 확보하는 것이 중요한 과제로 부상하고 있다[2]. 특히 학습자의 의사소통 의지를 효과적으로 자극하기 위해 구체적인 상황 제시가 요구된다[3].

전문가가 직접 학습자의 발화를 자연스럽게 이끌어낼 수 있는 상황을 설계하는 것은 많은 시간과 비용이 요구된다. 이에 대한 대안으로 LLM을 활용한 자동 문제 생성(Automatic Item Generation, AIG) 연구가 주목받고 있으며, 다양한 문제를 대규모로 산출할 수 있는 가능성을 보여주었다[4]. 다만 생성된 문제의 적합성, 난이도 조절, L2 학습자 친화성 측면에서는 여전히 한계가 존재하고[5], 전문가의 수동 검수에 의존하는 방식은 실질적 제약을 동반한다.

본 연구는 이러한 한계를 극복하기 위해 두 가지 방법론을 제안한다. 첫째, 한국어 sLLM 기반 자동 생성과 중형 LLM 기반 자동 평가를 결합한 파이프라인을 설계하여, 말하기 문제를 체계적으로 생산하고 루브릭에 따라 품질을 검증할 수 있도록 하였다. 둘째, 자동 생성 및 L2 적합성 평가 결과를 활용해 선호도 쌍(pairwise preference) 데이터셋을 자동 구축하고, 이를 바탕으로 소형 평가기를 학습하였다. 이를 통해 L2 학습자에게 적합한 문제를 효율적으로 선별하고 평가 비용을 경감할 수

있는 가능성을 탐구하였다.

연구 기여 (Contributions) 본 연구의 주요 기여는 다음과 같다.

- **말하기 문제 자동 생성 및 적합성 평가 파이프라인:** 한국의 일상생활과 관련된 250개 소재를 정의하고, sLLM(7~12B, 표 2 참고)으로 문제를 생성한 뒤 EXAONE-4.0-32B를 *LLM-as-a-Judge* 방식으로 활용하여 루브릭 기반 평가를 수행하였다[6]. 이를 통해 다양한 유형의 문제를 생산하고 품질을 검증하며 방법론의 실효성과 한계를 논의하였다.
- **선호도 데이터셋 구축 및 소형 평가기 학습:** 자동 생성 및 L2 학습자 적합성 평가 결과를 활용해 선호도 쌍 데이터셋을 자동으로 구축하고, 이를 이용해 2B 규모의 소형 평가기를 학습하였다. 학습된 모델은 중형 LLM 평가와 유의미한 순위 상관관계($\rho = 0.573$)를 보여, 평가 비용을 줄이면서도 더욱 세밀한 적합성 판별 가능성을 보였다.

제 2. 절 자동 문제 생성 및 평가

말하기 문제는 일반적으로 구체적인 상황을 제시하는 자료(content)와 간결하고 명료한 지시문(stem)로 구성된다. 자료는 학습자의 발화를 유도하는 지문, 대화 대본, 이미지 설명 형태의 텍스트로 생성된다. 지시문은 학습자에게 수행해야 할 발화 과제를 간결하게 제시하는 한 문장의 텍스트로 제시된다.




그림 1. 문항 자동 생성 및 평가 전체 파이프라인 개요. (좌) **Content Generation**: 주어진 평가 목표와 소재 설명을 기반으로 sLLM이 지문·대화 대본·이미지 설명을 생성. (중) **Stem Generation**: 생성된 자료에 따라 sLLM이 세 개의 지시문(stem)을 작성. (우) **Item Evaluation**: 전문가 모델(EXAONE-4.0-32B) 또는 보상 모델이 6개 루브릭(R1-R6)에 따라 문항 품질을 평가하고 최종 선별. 피드백은 정성적 분석에 사용했다.

2.1 문제 생성 명세 구축

본 연구에서는 이러한 구조를 반영하여, 모든 문제를 하나의 자료와 세 개의 지시문으로 구성하였다. 총 5개의 생성 명세(S1-S5)가 있으며, 각 명세마다 지시문을 생성하기 위한 세 가지 문제 유형과 평가 목표, 그리고 50개의 소재가 정의되었다. 전체적인 내용은 표 1에 요약하였다. 세부 프롬프트 템플릿과 데이터 구조는 공개된 GitHub 저장소¹에서 확인할 수 있다.

표 1. iSKA-Gen 명세 구성

명세 ID	생성 자료 유형	소재 수
S1	읽고 말하기-복합 소재 지문	50
S2	읽고 말하기-단일 소재 지문	50
S3	듣고 말하기-대화 대본(유형 1)	50
S4	듣고 말하기-대화 대본(유형 2)	50
S5	보고 말하기-사진 설명	50
총계		250

2.2 문제 적합성 평가 루브릭

본 연구에서는 문제의 품질을 검증하기 위해 사용할 정답(reference)이 존재하지 않으므로, reference-free 방식의 루브릭을 직접 정의하였다. 이 과정에서 Nguyen et al.[7]이 제안한 Naturalness, Answerability, Complexity 루브릭과, Liu et al.[6]의 gEval에서 활용된 Coherence, Consistency, Fluency 루브릭을 참고하여 한국어 말하기 문항에 특화된 여섯 가지 루브릭(R1-R6)을 도출하였다. 중형 LLM(32B)을 평가자로 활

용하는 만큼, 평가 난이도를 낮추고 일관성을 확보하기 위해 R1-R5는 모두 이진(PASS/FAIL) 판정 체계로 설계하였다. 이들은 각 문항이 평가 지침 충족, 주제 명확성, 참고 자료 기반성, 논리적 구조, 언어 품질을 충족하는지를 개별적으로 검증한다. 반면 R6은 리커트 5점 척도를 적용하여 L2 학습자에게의 응답 적합성을 세분화하여 측정한다. 제안된 루브릭은 문제의 정합성, 언어적 품질, L2 학습자 적합성을 종합적으로 평가하며, 세부 정의는 아래에 제시하였다. 생성된 자료의 특성에 따라 세부 기준은 변주된다.

루브릭 정의 (읽고 말하기 유형 예시)

- R1. **평가 지침 완전성** 지문과 세 개의 지시문이 주어진 평가 목표를 모두 충족하는지 여부를 이진(PASS/FAIL)으로 판정한다.
- R2. **핵심 주제 명확성** 지문이 일관된 상위 주제를 중심으로 전개되는지 여부를 평가한다.
- R3. **참고 자료 기반성** 지문이 제공된 참고 자료에 근거하고, 모순되거나 근거 없는 사실을 포함하지 않는지 판정한다.
- R4. **논리적 흐름 및 구조** 지문이 도입-본론-결론 구조를 갖추고 문장·문단 간 연결이 자연스러운지 평가한다.
- R5. **한국어 품질** 지문이 문법·맞춤법 오류 없이 자연스럽고 어색한 번역투가 없는지 여부를 확인한다.
- R6. **L2 학습자 적합성** 지문이 L2 학습자에게 어휘 수준과 문장 복잡도 면에서 적절한지 리커트 1-5점으로 평가한다.

¹https://github.com/sjin4861/iSKA_Gen

2.3 자동 문제 생성 파이프라인

그림 1의 좌측 *Content Generation* 단계는 생성 명세에 따라 말하기 평가에 필요한 자료(지문, 대화 대본, 이미지 설명 등)를 생성하는 과정이다. 주어진 소재와 문제 유형, 평가 목표를 기반으로 sLLM이 자료를 산출한다. 프롬프트에는 여섯 가지 루브릭을 명시하여 생성된 자료가 이후 지시문(stem)과 결합되었을 때 적합한 문제가 될 수 있도록 유도하였다.

중앙의 *Stem Generation* 단계는 이렇게 생성된 자료를 바탕으로 학습자가 실제로 응답할 수 있는 지시문(stem)을 작성하는 과정이다. 생성 명세에 포함된 문제 유형과 평가 목표, 자료를 프롬프트로 제공하면, sLLM이 총 세 개의 stem을 산출한다.

문제 생성에는 국내 기업(KT, SKT, LG)이 공개한 한국어 소형 언어 모델(sLLM)을 활용하였으며, 상세 정보는 표 2에 제시하였다.

표 2. 실험에 사용된 한국어 소형 언어 모델(sLLM) 상세 정보

모델 이름	개발사/출처	모델 크기 (반올림)	공개일자
EXAONE-3.5-7.8B-Instruct ¹	LG AI Research	8B	2024년 12월
A.X-4.0-Light ²	SK Telecom	7B	2025년 7월
Midm-2.0-Base-Instruct ³	K-intelligence	12B	2025년 7월
llama3.1-korean-v1.1-sft ⁴	SEOKDONG	8B	2024년 12월

¹ <https://huggingface.co/LGAI-EXAONE/EXAONE-3.5-7.8B-Instruct>

² <https://huggingface.co/skt/A.X-4.0-Light>

³ <https://huggingface.co/K-intelligence/Midm-2.0-Base-Instruct>

⁴ https://huggingface.co/SEOKDONG/llama3.1-korean-v1.1-sft_by_aidx

2.4 자동 적합성 평가 파이프라인

그림 1의 *Item Evaluation* 단계에서는 EXAONE-4.0-32B²이 각 루브릭에 따라 자동 평가를 수행하였다. 총 1000개의 문항을 평가한 결과, 표 3에서 보듯 A.X-4.0-Light는 R1-R5(이진) 전 항목에서 1등(98.0-100.0%)을 기록하고 R6(리커트)에서도 가장 높은 점수(4.52)를 얻어, 명세 충실성과 언어적 완성도 모두에서 가장 안정적인 성능을 보였다. 반면 EXAONE-3.5-7.8B와 Midm-2.0-Base-Instruct는 전반적으로 준수했으나 한국어 품질(R5)에서 낮은 점수를 보였는데, 이는 번역투적 표현이나 어색한 구절 사용이 주된 감점 요인이었다. 다만 이러한 평가는 단일 LLM의 평가의 편향으로 해석될 여지가 있고, 일부 오류로 단정하기 어려운 사례도 존재해 향후 전문가 검증이 필요하다. llama3.1-korean-v1.1-sft는 R1(60.8)이 현저히 낮았으며, 이는 그림 2와 같이 자료 생성에서 주어진 소재의 맥락을 이해하지 못하거나, 문제 유형 및 평가 목표를 바탕으로 지시문을 간결하게 생성하는 작업을 자주 실패했기 때문이었다.

특히 루브릭별로 평가의 신뢰성과 해석 가능성에는 차이가 있었다. R1-R4(평가 지침 완전성, 주제 명확성, 참고 자료 기

² <https://huggingface.co/LGAI-EXAONE/EXAONE-4.0-32B>



그림 2. llama3.1-korean-v1.1-sft 생성에서 관찰된 오류 사례 (S4의 41번째 소재). 소재를 오해한 것으로 판단되며, 구어체가 자연스럽지 않다. A.X-4.0-Light와 비교하면 생성 수준의 차이가 드러난다. 추가로 “존댓말”과 같은 오류 토큰을 생성하는 사례가 관찰되었다.

표 3. 모델별 루브릭 평균 결과

모델 이름	$\overline{R1}^B$	$\overline{R2}^B$	$\overline{R3}^B$	$\overline{R4}^B$	$\overline{R5}^B$	$\overline{R6}^L$
EXAONE-3.5-7.8B-Instruct	98.0	100.0	95.2	99.2	90.0	4.24
llama3.1-korean-v1.1-sft	60.8	96.8	86.4	96.0	94.4	4.21
A.X-4.0-Light	98.4	100.0	98.0	100.0	98.4	4.52
Midm-2.0-Base-Instruct	90.0	98.8	95.6	99.6	87.2	4.46

범례: B = 이진 (PASS 비율, %), L = 리커트 (1-5 평균 점수).

루브릭 ID 위/아래 선은 평가 범위를 의미한다 (overline = 자료+지시문, underline = 자료만).

반성, 논리적 구조)는 마치 고도화된 조건 검증(if-statement)처럼 작동했으며, FAIL 판정을 받은 사례를 정성적으로 검토했을 때 충분히 타당성이 있었다. 반면 R5(한국어 품질)는 번역투나 미세한 표현상의 어색함을 일관되게 판별하지 못하는 경향이 있었다. 실제 맞춤법 오류가 제대로 검출되지 않거나, 경미한 오류가 과대평가되는 사례가 관찰되었다. 따라서 향후에는 고도화된 문법 교정 모델을 도입하거나 전문가 기반의 세밀한 지침이 보완될 필요가 있다.

R6(L2 학습자 적합성)은 리커트 척도를 사용했으나 점수가 3-5점 구간에 집중되었고, 1-2점은 부여되지 않았다. 이는 LLM이 대체로 L2 학습자에게 적합한 문제를 생성했음을 시사하지만, 가령 3점을 받은 문항들 사이에서도 품질 차이를 정밀하게 변별할 필요성이 제기된다. 따라서 본 연구는 데이터 기반 평가 방식을 도입하여 보다 세밀한 적합성 평가의 가능성을 탐구하였다. 구체적인 구현 과정은 다음 장에서 서술한다.




그림 3. 선호도 데이터셋 구축 방식 개요. (좌) 자동 적합성 평가 단계에서 부여된 점수를 활용하여 동일 소재에서 생성된 자료를 선호도 쌍으로 구성하는 EMPG, (우) 자동 생성 단계에서 루브릭 위반 응답을 고의로 생성하도록 지시하여 대비되는 자료를 구성하는 CPG.

제 3. 절 소형 평가기 개발 및 검증

앞선 장에서 언급했듯, 자동 적합성 평가 파이프라인의 R6은 동일한 점수를 받은 문제들 사이의 세부적 품질 차이를 구별하는 데 한계가 있었다. 이를 보완하기 위해 본 연구에서는 R6에 대한 선호도 쌍 자료를 수집하고, 이를 기반으로 입력 자료를 받아 점수를 산출하는 소형 평가기(small evaluator)를 훈련하였다.

3.1 선호도 데이터셋 구축

그림 3과 같이 소형 평가기 학습을 위해 두 가지 방식의 선호도 쌍(pairwise preference) 데이터셋을 구축하였다. **CPG (Contrastive Preference Generation)**는 동일한 sLLM에게 특정 루브릭을 의도적으로 위반하도록 지시하여 저품질 응답을 생성하고, 이를 정상 응답과 대비시켜 (x, y^+, y^-) 형태의 쌍을 구성하는 방식이다. 다만, 이러한 방식의 경우 품질 격차가 지나치게 단순화되어 모델이 극단적 선호에만 반응하는 이진 분류적 행동으로 수렴하거나, 특정 생성기의 표면적 단서에 과적합하여 미세한 품질 차이를 포착하지 못할 위험이 있다[8]. 이를 보완하기 위해, **EMPG (Expert-Model Preference Generation)**를 병행하였다. EMPG는 그림1의 *Item Evaluation* 단계에서 R6에 대한 자동 평가 점수를 활용하여 동일 소재로 생성된 자료가 점수 차이가 있으면 높은 점수의 자료를 선호, 낮은 점수의 자료를 비선호 쌍으로 묶는 방식이다. 이를 통해 CPG 방식이 놓칠 수 있는 생성기 분포 차이와 미세한 품질 신호를 학습하여 세밀한 변별을 지원할 수 있을 것으로 기대했다.




그림 4. 소형 평가기의 학습 및 추론 구조. (좌) 학습 단계에서는 프롬프트 (x)와 후보 응답 (y^+ , y^-)을 입력받아, 선택된 응답(y^+)의 점수가 거부된 응답(y^-)보다 높아지도록 Pairwise Loss를 최소화한다. (우) 추론 단계에서는 프롬프트 (x)와 단일 응답 (y)가 입력되며, 모델은 최종적으로 스칼라 점수를 출력한다.

3.2 소형 평가기 학습

본 연구의 소형 평가기는 Midm-2.0-Mini-Instruct³를 backbone으로 사용하고, 그 위에 스칼라 보상 점수를 출력하는 선형 헤드를 추가하였다. 입력은 프롬프트 (x)와 응답 (y)를 연결한 시퀀스로, 모델은 최종적으로 $r_\theta(y|x) \in R$ 형태의 점수를 산출한다. 학습에는 효율성을 위해 LoRA (Low-Rank Adaptation)를 적용하였다.

학습 설정. 모델 학습에는 앞서 구축한 CPG와 EMPG 기반 선호도 데이터셋(triplet)을 사용하였으며, 이를 9:1 비율로 학습·검증 세트로 분할하였다. 목적 함수는 *Pairwise Loss*로 정의되어, 선호 응답 y^+ 가 비선호 응답 y^- 보다 높은 점수를 갖도록 학습한다:

$$\mathcal{L}_{\text{pairwise}} = -\log \sigma(r_\theta(y^+|x) - r_\theta(y^-|x)),$$

여기서 $\sigma(\cdot)$ 는 시그모이드 함수이다. 검증 단계에서는 각 pair (x, y^+, y^-)에 대해 $r_\theta(y^+|x) > r_\theta(y^-|x)$ 가 성립하는 비율을 **Accuracy**로 측정하여 모델의 구분 능력을 평가하였다. 전체적인 학습 하이퍼파라미터는 표 4와 같다.

그림 5는 학습 과정에서의 *train loss*, *eval loss*, *eval accuracy*의 변화를 보여준다. 학습은 안정적으로 0에 수렴하였으며, eval accuracy 역시 빠르게 향상된 뒤 1에 근접한 수준에서 유지되었다.

³<https://huggingface.co/K-intelligence/Midm-2.0-Mini-Instruct>




그림 5. 소형 평가기 학습 과정에서의 손실 값과 평가 정확도 변화. 학습 초기에는 빠르게 수렴하며, 평가 정확도는 손실값과 반비례하여 안정적으로 향상됨을 확인할 수 있다.

3.3 소형 평가기 평가 및 상관관계 검증

그림 4의 *Testing* 단계에서와 같이, 프롬프트 (x)와 단일 응답 (y)가 입력되면 소형 평가기는 스칼라 점수를 산출한다. 이를 자동 평가에 사용했던 EXAONE-4.0-32B의 리커트 점수와 대조하여, 동일한 테스트 데이터에 대해 두 모델이 내린 평가가 얼마나 일관되게 순위를 매기는지를 검증하였다. 분석에는 비모수적 순위 기반 상관관계수인 **Spearman's ρ** 를 사용하였으며, 상관계수 ρ 와 유의확률(p-value)은 Python의 `scipy.stats.spearmanr` 함수를 통해 산출하였다.

테스트셋 구성. 각 생성 명세 ID마다 10개의 소재(Topic)를 선정하였으며, 이 중 절반은 학습 시 사용된 소재(Seen Topic), 나머지는 학습 시 전혀 등장하지 않은 소재(Unseen Topic)로 구성하였다. 표 2의 모델로부터 테스트 생성 명세에 대한 응답을 수집하였는데, 이 과정에서 CPG와 동일한 방식으로 두 가지 유형의 프롬프트를 사용하였다. 즉, 하나는 일반적인 프롬프트로 응답을 생성하고, 다른 하나는 루브릭을 무시하도록 지시하는 프롬프트를 사용하여 응답을 생성하였다. 각각의 방식에서 200개씩, 총 400개의 자료를 테스트셋으로 구성했다.

결과. 그림 6에 나타난 바와 같이, 소형 평가기의 점수와 중형 LLM 점수 간 Spearman 상관계수는 전체적으로 $\rho = 0.573(p < 0.0001)$ 로, 중간 수준의 양의 상관관계를 보였다. 테스트셋에서 대부분의 문항이 3~4점 구간에 분포하였는데, 소형 평가기는 이 구간 내에서도 분포를 뚜렷하게 갈라내는 경향을 보여 상위권 문항 간의 세부 구분을 지원할 가능성을 시사한다.

소형 평가기는 자동 평가에서 R1-R5를 모두 충족하고 R6에서도 상대적으로 높은 점수를 받은 항목에 한정할 경우, 추




그림 6. 보상 모델 점수와 EXAONE-4.0-32B 리커트 점수 간 상관관계. 데이터셋을 나누어 분석한 결과, 학습 시 사용된 소재(Seen Topic, Case 1)와 새로운 소재(Unseen Topic, Case 2) 모두에서 양의 상관관계가 나타났다.

가적인 변별 신호를 제공하여 L2 학습자 적합성이 높은 문항들 사이의 세부적인 서열화를 보완하는 *보조적 도구*로 의미를 가질 수 있다. 다만 소형 평가기가 부여한 점수가 실제 학습자의 체감 난이도나 적합성을 직접적으로 반영한다고 단정하기는 어렵기에, 향후에는 전문가 및 학습자 평가와의 체계적인 비교 검증이 반드시 요구된다.

이러한 점을 종합하면, 본 연구의 결과는 소형 평가기가 자동 생성 및 적합성 평가 파이프라인으로부터 일종의 지식 증류 효과를 얻을 수 있음을 보여준다. 또한 소형 평가기는 단일 LLM 평가의 편향을 보완하고, 상위권 문항 간의 세밀한 변별을 지원하는 실질적 도구로 활용될 수 있음을 시사한다.

제 4. 절 결론 및 향후 연구

본 연구는 한국어 sLLM을 활용해 L2 학습자 말하기 평가용 문항을 자동 생성하고, 여섯 가지 루브릭을 기반으로 정량 평가하였다. 그 결과, A.X-4.0-Light 모델이 가장 안정적인 성능을 보여 한국어 sLLM 기반 문항 생성의 가능성을 입증하였다. 또한 자동 파이프라인에서 수집한 데이터를 활용해 선호도(pairwise preference) 데이터셋을 자동으로 구축하고, 이를 바탕으로 소형 평가를 학습함으로써 R6(L2 학습자 적합성)에 대한 세밀한 판별 가능성을 확인하였다.

향후 연구는 다음과 같이 확장될 수 있다.

1. **문항 생성의 모달리티 확장:** 텍스트 기반을 넘어 이미지·오디오를 포함한 멀티모달 문항을 자동 생성하여 실제 말하기 시험과 유사한 응답 상황을 구현할 필요가 있다. 이를 통해 보다 몰입적인 문제를 생성할 수 있다.

2. **강화학습 기반 생성 모델 개선:** 소형 평가기를 critic으로 확장하여 PPO 등 강화학습 기법에 적용함으로써, 자동 생성 파이프라인의 모델 성능을 한층 더 향상시킬 수 있다. 이를 통해 생성 모델이 학습자 맞춤형 문항을 점진적으로 개선할 수 있는 기반을 마련할 수 있다.
3. **사람 평가와의 연계 및 검증:** 장기적으로는 전문가 및 학습자 평가와의 체계적 비교를 통해 자동 평가 방법론의 타당성을 검증하고, 실제 시험 환경에서의 신뢰할 수 있는 보조 도구로 자리매김할 필요가 있다.

감사의 글

본 연구는 과학기술정보통신부 및 정보통신기획평가원의 대학ICT연구센터육성지원사업(IITP-2025-RS-2020-II201789)과 문화체육관광부 및 한국콘텐츠진흥원의 2025년도 문화기술 연구개발사업 (과제명: 외국인의 효율적인 한국어 말하기 학습을 위한 AI 활용 한국어 진단 시스템 개발, 과제번호: RS-2025-02413038)의 지원을 받아 수행되었으며, 두 과제는 각각 50%씩 기여하였다.

부록 A 실험 환경 및 하이퍼파라미터

랜덤 시드 고정. 실험의 재현성을 보장하기 위해 소형 적합성 평가 모델(small evaluator)이 추론할 때는 `set.seed(42)` 함수를 사용하여 `random`, `numpy`, `torch`의 시드를 고정하고 `cuda` 설정을 통제하였다.

하이퍼파라미터. 소형 적합성 평가 모델 훈련에 사용한 주요 하이퍼파라미터는 표 4에 정리하였다.

표 4. 훈련에 사용된 하이퍼파라미터 (통제 변인)

하이퍼파라미터	값
Learning Rate	5×10^{-5}
Epochs	5
Effective Batch Size	16
- per_device_train_batch_size	4
- gradient_accumulation_steps	4
Max Sequence Length	1024
LoRA Hyperparameters	
r	16
lora_alpha	32
lora_dropout	0.05

생성 하이퍼파라미터. 소형 언어 모델의 문항 생성에는 표 5과 같은 설정을 적용하였다. EXAONE-4.0-32B의 경우는 평가

안정성을 위해 `temperature`를 0.1로 낮추어 사용하였다.

표 5. 문항 생성 시 sLLM 하이퍼파라미터

설정	값
max_new_tokens	1024
temperature	0.7
repetition_penalty	1.1
top_p	0.9
top_k	50

참고문헌

- [1] Y. Han, J.-M. Dewaele, and J. Kiaer, “Does the attractiveness of k-culture shape the enjoyment of foreign language learners of korean?” *International Journal of Applied Linguistics*, Vol. 35, No. 1, pp. 486–502, 2025.
- [2] 민병곤 and 이성준, “학문 목적 한국어 말하기 평가 도구 개발의 쟁점과 과제,” *국어교육연구*, Vol. 38, pp. 67–110, 2016.
- [3] 린천천, “실시간 온라인 수업에서 중국인 한국어 학습자들의 의사소통 의지에 미치는 영향 요인에 대한 연구,” *화법연구*, Vol. 56, pp. 1–39, 2022.
- [4] J. Chen, R. Qadri, Y. Wen, N. Jain, J. Kirchenbauer, T. Zhou, and T. Goldstein, “Genqa: Generating millions of instructions from a handful of prompts,” *arXiv preprint arXiv:2406.10323*, 2024.
- [5] R. Circi, J. Hicks, and E. Sikali, “Automatic item generation: foundations and machine learning-based approaches for assessments,” *Frontiers in Education*, Vol. 8, p. 858273, 2023.
- [6] Y. Liu, D. Iter, Y. Xu, S. Wang, and J. Glass, “G-eval: A new paradigm for evaluating generated text,” *arXiv preprint arXiv:2303.16634*, 2023.
- [7] B. Nguyen, M. Yu, Y. Huang, and M. Jiang, “Reference-based metrics disprove themselves in question generation,” *arXiv preprint arXiv:2403.12242*, 2024.
- [8] S. Huang, J. Zhao, Y. Li, and L. Wang, “Learning preference model for llms via automatic preference data generation,” *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pp. 9187–9199, 2023.